BU ÖRNEK FORMDUR, PROJE BİLGİLERİNİ KENDİ PROJENİZE GÖRE DOLDURUNUZ.

Karamanoğlu Mehmetbey Üniversitesi

Mühendislik Fakültesi

Bilgisayar Mühendisliği Bölümü

Bitirme Dersi Proje Formu

Proje Başlığı
Mobil Bitki Hastalığı Tespit Sistemi

Öğrenci Bilgileri	
Öğrenci No	211312039
Öğrenci Ad Soyad	Merve Akbaba

Danışman ünvan Ad Soyad

Proje Raporu Hazırlama Kuralları

Her öğrenci bitirme projesini aşağıda belirlenen kurallara göre hazırlayacaktır.

1. **Rapor Bölümleri**
   - Kapak
   - İçindekiler
   - Projenin Önemi
   - Projenin Amacı
   - Projenin Hedefi
   - Projenin iş-zaman çizelgesi
   - Projede kullanılan donanımlar ve yazılımlar ile ilgili bilgileri.
   - Projenin yapım aşamaları.
   - Kaynaklar
2. **Konu Anlatımı**
   - Etik kurallara uygun olarak, öğrenci konuyu kendi cümleleri ile sade bir şekilde anlatmalıdır. Yararlanılan kaynaklar belirtilmelidir.
3. **Sayfa Düzeni**
   - Kenar Boşlukları: 2.5 cm
   - Sayfa Numarası: Sağ Alt Köşede Projenin Önemi sayfasından itibaren başlamalıdır.
4. **Metin Özellikleri**
   - Paragraf Girintisi Yok
   - Metin iki yana yaslı
   - Tek satır aralıklı
   - 12 Punto ve Normal
   - Paragraflar arasında 1 boşluk
   - Ana Başlıklar ve alt Başlıklar: 12 Punto ve Kalın
   - Tüm Metin Fontu: Times New Roman
5. **Şekiller ve Tablolar**
   - Şekiller sayfa içerisinde ortalı olmalıdır.
   - Şekil açıklama metni şekil altında ortalı olmalıdır.
   - Tablolar sayfa içerisinde ortalı olmalıdır
   - Tablo açıklama metni tablo üstünde ve ortalı olmalıdır.
6. **Kaynaklar**
   - Bitirme projesinde hazırlanmasında yararlanılan kaynaklar, metin içerisinde kullanım sırasına göre rapor sonunda ve "Kaynaklar" başlığı altında sıra numaraları verilerek listelenecektir.

Proje çalışmalarınızda başarılar…

İçindekiler

1. Proje Konusunun Önemi ve Özgün Değeri 4
2. Projenin Amacı ve Hedefi 4
3. Projenin iş-zaman çizelgesi 5
4. Projede kullanılacak yöntem, donanımlar ve yazılımlar ile ilgili bilgiler 7
5. Projenin yapım aşamaları 7
Kaynaklar 15

1. Proje Konusunun Önemi ve Özgün Değeri

Önemi

Bitki hastalıkları, tarımsal üretimde verim ve kalite kaybına neden olan en kritik sorunlardan biridir. Hastalıkların erken aşamada tespit edilememesi ürün kayıplarını artırmakta ve büyük ekonomik zararlara yol açmaktadır. Bu proje kapsamında geliştirilen web tabanlı bitki hastalığı analiz platformu, kullanıcıların herhangi bir uygulama indirmesine gerek kalmadan, doğrudan tarayıcı üzerinden bitki yapraklarının görüntülerini analiz ederek hastalıkların hızlı ve doğru bir şekilde tespit edilmesini sağlamaktadır. Bu sayede üreticiler, profesyonel tarım desteğine ihtiyaç duymadan bitkilerdeki sorunları erken fark ederek gerekli önlemleri zamanında alabilecektir. Platformun web tabanlı olması, internet erişimi olan tüm bilgisayar, tablet ve akıllı telefonlardan işletim sistemi kısıtlaması olmaksızın anında erişilebilirliği garanti etmektedir.

Özgün Değeri

Projenin özgün değeri; 51 farklı bitki hastalık kombinasyonunu içeren geniş bir yelpazede, derin öğrenme tabanlı görüntü analizini platform bağımsız çalışan web mimarisine taşımasıdır. Geliştirilen modelde, düşük hesaplama gücüyle yüksek verim sunan MobileNetV2 mimarisi kullanılmıştır. Modelin sunucu veya yerel sunucu üzerinde gecikmesiz ve gerçek zamanlı tahmin üretebilmesi amacıyla, TensorFlow Lite altyapısı kullanılarak optimizasyon sağlanmıştır. Arayüz tarafında kullanılan Streamlit teknolojisi, karmaşık web sunucu süreçlerini ortadan kaldırarak kullanıcıya doğrudan kamera ve dosya yükleme yetenekleri sunan, optimize edilmiş ve yüksek performanslı bir kullanıcı deneyimi sağlamaktadır.

Projenin Amacı ve Hedefi

Amacı

Bu projenin temel amacı; kullanıcıların bilgisayar veya akıllı telefon tarayıcılarını kullanarak, ek bir kuruluma ihtiyaç duymadan bitki yapraklarından anlık hastalık teşhisi yapabilmelerini ve teşhis sonrasında uzman müdahale stratejilerine ulaşabilmelerini sağlayan uçtan uca, web tabanlı bir analiz platformu geliştirmektir

Hedefi

51 farklı sınıfı yüksek doğruluk oranıyla sınıflandırabilen bir derin öğrenme modeli eğitmek.

Eğitilen modeli optimize ederek web sunucu mimarisine entegre etmek.

Kullanıcı dostu, sade ve profesyonel bir web arayüzü tasarlayarak tarayıcı üzerinden canlı kamera ve dosya yükleme modüllerini devreye almak.

Tahmin edilen her patoloji için arka planda yapılandırılmış uzman tavsiyelerini ve müdahale stratejilerini dinamik olarak kullanıcı ekranına basmak.

2. Projenin iş-zaman çizelgesi

Projede yer alacak başlıca iş paketleri (İP), hedefleri ve her bir iş paketinin hangi sürede gerçekleştirileceği "İş-Zaman Çizelgesi" doldurularak verilir.

İş-zaman çizelgesi

İP No	İş Paketinin Adı ve Hedefleri	Zaman Aralığı (Haftalık)
1	**İş Paketinin Adı:** **Hedefleri** :Proje konusunun belirlenmesi ve proje kapsamının oluşturulması. Bitki hastalıklarının görüntü işleme ve yapay zeka yöntemleri ile tespit edilmesi üzerine literatür araştırmasına başlanması.	1. hafta
2	**İş Paketinin Adı:** **Hedefleri** Benzer çalışmaların incelenmesi ve literatür araştırmasının devam ettirilmesi. Kullanılacak yöntemlerin belirlenmesi ve proje için gerekli teknolojilerin planlanması.	2. hafta
3	**İş Paketinin Adı:** **Hedefleri** Bitki hastalıklarını içeren görüntü veri setlerinin araştırılması ve uygun veri setinin seçilmesi. Projede kullanılacak veri setinin indirilmesi ve incelenmesi.	3.hafta
4	**İş Paketinin Adı:** H**edefleri** Veri setinin düzenlenmesi ve ön işleme adımlarının gerçekleştirilmesi. Görüntülerin boyutlandırılması ve eğitim için uygun hale getirilmesi.	3. hafta
5	**İş Paketinin Adı:** Hedefleri Görüntü sınıflandırma modeli tasarımına başlanması.Derin öğrenme yöntemi olarak Convolutional Neural Network mimarisinin oluşturulması.	4. hafta
6	**İş Paketinin Adı:** **Hedefleri** Modelin eğitilmesi ve ilk sonuçların elde edilmesi. Model performansının değerlendirilmesi ve gerekli iyileştirmelerin planlanması.	5. hafta
7	**İş Paketinin Adı:** **Hedefleri** Model üzerinde iyileştirmeler yapılması ve yeniden eğitilmesi. Model doğruluk oranının artırılması için parametre ayarlamalarının yapılması.	6. Hafta
8	**İş Paketinin Adı:** Model Optimizasyonu ve Dönüştürme İşlemleri	8. hafta

	Hedefleri : Eğitilen yüksek boyutlu modelin web platformu üzerinde düşük gecikmeyle çalışabilmesi amacıyla TensorFlow Lite (.tflite) formatına dönüştürülmesi ve model sıkıştırma işlemlerinin tamamlanması.	
9	**İş Paketinin Adı:** Web Geliştirme Ortamının Hazırlanması ve Arayüz Tasarımı **Hedefleri:** Python tabanlı Streamlit framework altyapısının kurulması, gerekli kütüphane bağımlılıklarının tanımlanması ve web platformunun temel iskelet arayüz ekranlarının kodlanmaya başlanması.	9.hafta
10	**İş Paketinin Adı:** Tarayıcı Tabanlı Kamera ve Veri Giriş Entegrasyonu **Hedefleri:** Web uygulaması üzerinde kullanıcıların anlık görüntü sağlayabilmesi için tarayıcı izinli canlı kamera erişim modülünün ve dosya yükleme (uploader) bileşeninin geliştirilmesi.	10. hafta
11	**İş Paketinin Adı:** Yapay Zekâ Modelinin Web Platformuna Entegre Edilmesi **Hedefleri:** Optimize edilen TensorFlow Lite modelinin Streamlit mimarisine dahil edilmesi; sisteme giren ham yaprak görüntülerinin boyutlandırma ve normalizasyon fonksiyonlarının (görüntü ön işleme) kodlanması.	11. hafta
12	**İş Paketinin Adı:** Teşhis ve Analiz Bulguları Arayüzünün Geliştirilmesi **Hedefleri:** Model çıktılarının (np.argmax) işlenerek saptanan patoloji adının ve teşhis doğruluk oranının web arayüzünde şık ve okunabilir kart yapıları (panel-container) halinde kullanıcıya sunulması.	12. hafta
13	**İş Paketinin Adı:** Uzman Müdahale Stratejileri Modülünün Oluşturulması **Hedefleri:** Teşhis edilen 51 farklı hastalık ve bitki sınıfı için arka planda çalışacak Türkçe uzman tavsiyeleri sözlüğünün tavsiyeler.py adıyla modüler hale getirilerek sisteme bağlanması.	13. hafta
14	**İş Paketinin Adı:** Sistem Optimizasyonu ve Görsel Arayüz İyileştirmeleri **Hedefleri**: Web platformunun kullanıcı deneyimini artırmak adına yazı boyutlarının, butonların ve dinamik girdi türlerinin profesyonel standartlara getirilmesi; proje raporunun yazım sürecine başlanması.	14. hafta
15	**İş Paketinin Adı:** Sistem Testleri, Doğrulama ve Raporlama **Hedefleri:** Geliştirilen web platformunun farklı bitki görselleriyle uçtan uca test edilmesi, çalışma kararlılığının doğrulanması ve bitirme projesi nihai raporunun tamamlanarak teslim aşamasına getirilmesi.	15. hafta

İhtiyaç olursa tabloya yeni satır eklenebilir

7. Projede Kullanılan Yöntem, Donanımlar ve Yazılımlar ile İlgili Bilgiler

Kullanılan Yazılımlar

- **Python Programlama Dili:** Derin öğrenme modelinin veri ön işleme, eğitim, test ve optimizasyon süreçlerinin yürütülmesinde; aynı zamanda Streamlit tabanlı web arayüz bileşenlerinin modüler olarak kodlanmasında temel programlama dili olarak kullanılmıştır.
- **TensorFlow:** Google tarafından geliştirilen açık kaynaklı makine öğrenmesi platformu, projede Convolutional Neural Network (CNN) mimarisinin uçtan uca inşa edilmesi, katmanların yapılandırılması ve transfer öğrenme süreçlerinin yönetilmesi amacıyla ana kütüphane olarak tercih edilmiştir.
- **Keras:** TensorFlow üzerinde üst seviye bir API olarak çalışan bu kütüphane, derin öğrenme modelinin katman kombinasyonlarının hızlıca prototiplenmesini, Dropout ve Dense katmanlarının esnek bir şekilde sisteme dahil edilmesini sağlamıştır.
- **TensorFlow Lite (TFLite):** Eğitilen yüksek boyutlu derin öğrenme modelinin web platformu üzerinde hızlı, optimize ve düşük gecikmeli tahminler üretebilmesi amacıyla ağırlık dönüşümü ve model sıkıştırma işlemlerinde kullanılmıştır.
- **Streamlit Framework:** Python tabanlı açık kaynaklı bir web framework'ü olup, projenin tüm kullanıcı arayüzünün tasarlanmasında, tarayıcı tabanlı canlı kamera entegrasyonunda ve model çıktılarının anlık olarak görselleştirilmesinde ana web çerçevesi olarak kullanılmıştır.
- **NumPy:** Çok boyutlu matris operasyonları, görüntü verilerinin sayısal dizilere dönüştürülmesi ve model girdisi haline getirilmeden önceki normalizasyon süreçlerinde yüksek performanslı hesaplama motoru olarak kullanılmıştır.
- **Pillow (PIL):** Sisteme yüklenen veya kamera aracılığıyla anlık olarak yakalanan farklı formatlardaki (.jpg, .jpeg, .png) bitki yaprağı görüntülerinin okunması, RGB renk uzayına dönüştürülmesi ve işlenmesi amacıyla kullanılmıştır.
- **Matplotlib:** Modelin 10 epoch süren eğitim aşaması boyunca ürettiği eğitim doğruluk, doğrulama doğruluk, eğitim kaybı ve doğrulama kaybı (Accuracy/Loss) grafiklerinin matematiksel olarak çizilmesi ve performans analizinde kullanılmıştır.
- **Scikit-learn:** Modelin genel başarısını nesnel metriklerle ölçmek adına; doğruluk (accuracy) oranı hesaplamalarında, sınıflandırma raporlarının (classification report) çıkarılmasında ve 51 sınıfın birbiriyle olan tahmin ilişkisini gösteren karışıklık matrisinin (confusion matrix) oluşturulmasında kullanılmıştır.
- **Google Colab:** Bulut tabanlı geliştirme ortamı, derin öğrenme modelinin eğitim safhasında ihtiyaç duyulan yüksek işlem gücünü karşılamak ve eğitim süresini minimuma indirmek amacıyla kullanılmıştır.
- **Visual Studio Code / PyCharm:** Projenin web arayüz tasarım kodlarının yazılması, tavsiyeler.py modülünün entegrasyonu, yerel sunucu testlerinin yürütülmesi ve kod

hata ayıklama (debugging) süreçlerinde tümleşik geliştirme ortamı (IDE) olarak tercih edilmiştir.

Kullanılan Donanımlar

- **NVIDIA GPU Destekli Bulut Sunucu (Google Colab Altyapısı):** Milyonlarca pikselden oluşan bitki hastalığı veri setinin matrisel hesaplamalarını ve evrişimli sinir ağı katmanlarının eğitim süreçlerini hızlandırmak amacıyla yüksek performanslı donanım hızlandırıcı olarak kullanılmıştır.
- **Kişisel Bilgisayar (Geliştirme İstasyonu):** Kaggle ve Mendeley gibi platformlardan ham veri setlerinin indirilmesi, verilerin ayıklanması, yerel Streamlit web sunucusunun ayağa kaldırılması, VS Code üzerinde arayüz kodlamalarının yapılması ve proje raporunun yazılması süreçlerinde ana işlem birimi olarak kullanılmıştır.
- **Tümleşik / Harici Web Kamerası (Webcam):** Geliştirilen platformun "Kamera Entegrasyonu" modülü aktif edildiğinde, tarayıcı üzerinden canlı olarak bitki yaprağı görüntülerinin yakalanması ve otonom analiz motoruna ham görsel veri beslemesi yapılması amacıyla donanım giriş birimi olarak kullanılmıştır.
- **Akıllı Telefon / Tablet (Test Cihazları):** Geliştirilen platformun web tabanlı ve platform bağımsız (responsive) yapısını doğrulamak amacıyla, farklı ekran çözünürlüklerine ve işletim sistemlerine (Android/iOS) sahip mobil cihazlar üzerinden tarayıcı tabanlı testlerin yürütülmesinde kullanılmıştır.

8. Projenin yapım aşamaları

Haftalık yaptığınız çalışmaları buraya yazacaksınız. Vize sınavına ve final sınavına gelmeden önce, o tarihe kadar olan önceki haftaları doldurmuş olmalısınız.

1. Hafta:

Proje konusunu belirledim. Projem bitkilerin yapraklarına bakarak bitkilerdeki hastalıkları analiz eden bir mobil uygulama olmasına karar verdim.

2. Hafta:

Benzer projeleri inceledim .

Plant Diseases Detector (Android + TensorFlow Lite)

https://github.com/obeshor/Plant-Diseases-Detector

Bu proje bitki hastalıklarını tespit eden uçtan uca bir mobil uygulama geliştirmeyi amaçlamaktadır. Projede Python ve TensorFlow kullanılarak bir derin öğrenme modeli eğitilmiş ve daha sonra model TensorFlow Lite formatına dönüştürülerek Android uygulamasına entegre edilmiştir. Uygulama, kullanıcıdan alınan bitki görüntüsünü analiz ederek hastalığı tahmin etmektedir.

Plant Disease Detection and Solution

https://github.com/DevilStudio27/Plant-Disease-Detection-and-Solution

Bu projede görüntü sınıflandırma yöntemi kullanılarak bitki hastalıklarının tespit edilmesi amaçlanmıştır. Sistem iki bölümden oluşmaktadır: makine öğrenmesi modeli ve Android mobil uygulaması. Kullanıcı bitkinin fotoğrafını çektiğinde görüntü modele gönderilmekte ve sistem hastalığı belirleyerek kullanıcıya hastalık hakkında bilgi ve çözüm önerileri sunmaktadır**.**

PlantDoctor – AI Plant Disease Detection

https://sami-fd.github.io/planty/

PlantDoctor, mobil cihazlarda çalışan bir yapay zekâ uygulamasıdır. Uygulama, telefon kamerası ile çekilen bitki yapraklarını analiz ederek yaklaşık 38 farklı bitki hastalığını tespit edebilmektedir. Model mobil cihaz üzerinde TensorFlow Lite ve MobileNetV2 kullanılarak çalıştırılmakta ve sonuçlar kullanıcıya anında gösterilmektedir.

Tomato Plant Disease Detection Model

https://github.com/its-kumar-yash/Tomato-Plant-Disease-Detection-Model

Bu projede domates bitkilerindeki hastalıkları tespit etmek için hafif bir makine öğrenmesi modeli geliştirilmiştir. Model yaklaşık 16.000 görüntü içeren bir veri seti ile eğitilmiş ve mobil cihazlarda çalışabilecek şekilde optimize edilmiştir. Projede TensorFlow Lite ve TinyML teknikleri kullanılmıştır.

3. Hafta:

Projemde kullanmak üzere veri setleri araştırdım ve uygun olabilecek veri setlerini inceledim. Kaggle, Mendeley ve GitHub üzerinden 51 farklı sınıfı (Domates, Patates, Pamuk, Muz, Pirinç, Çay vb.) içeren kapsamlı bir veri seti topladım. Veri setinin dengeli dağılımını kontrol ederek proje için uygun hale getirdim.

https://www.kaggle.com/datasets/nirmalsankalana/plant-disease-test-dataset

https://www.kaggle.com/datasets/rashikrahmanpritom/plant-disease-recognition-dataset

https://www.kaggle.com/datasets/kareem3egm/cucumber-plant-diseases-dataset

https://www.kaggle.com/datasets/vipoooool/new-plant-diseases-dataset

https://www.kaggle.com/datasets/emmarex/plantdisease

https://github.com/spMohanty/PlantVillage-Dataset?utm_source=chatgpt.com

https://data.mendeley.com/datasets/93h9p62kg4/1

https://data.mendeley.com/datasets/jttrv2w27r/2

https://www.kaggle.com/competitions/plant-pathology-2020-fgvc7

4. **Hafta**:

Ham görüntüler 224x224 boyutlarına yeniden boyutlandırıldı. ImageDataGenerator kullanılarak tüm piksel değerleri [0, 1] aralığına normalize edildi. Veri seti, modelin başarısını tarafsız ölçmek için %80 eğitim ve %20 doğrulama (validation) olarak ikiye ayrıldı.

5. **Hafta**:
   Modelin farklı çevresel koşullarda (farklı ışık, açı ve mesafe) yüksek başarı göstermesi için veri artırma stratejileri belirlendi. Görüntülere rastgele 20 derece döndürme, %20 yakınlaştırma (zoom), yatay çevirme ve kaydırma işlemleri uygulandı.
6. **Hafta**

Mobil cihazlarda düşük kaynak tüketimi ve yüksek hız sunan **MobileNetV2** mimarisi temel alındı. ImageNet ağırlıkları kullanılarak transfer öğrenme (transfer learning)

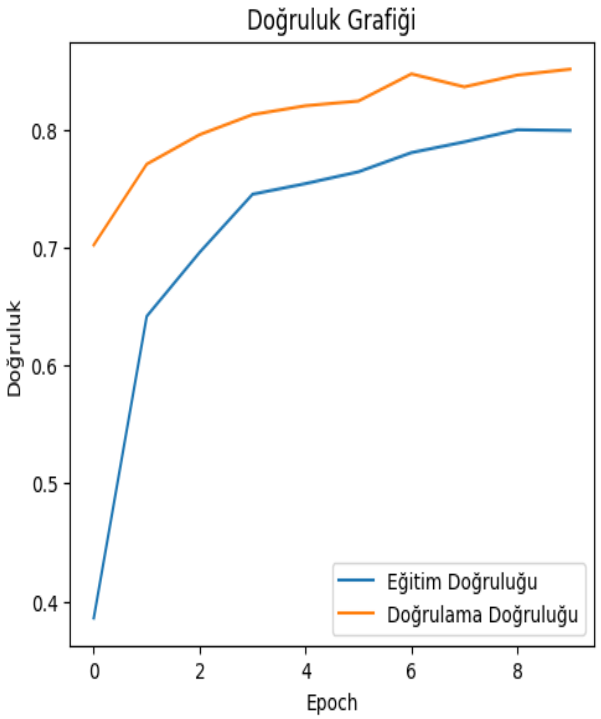
yöntemi uygulandı. Modelin sonuna Global Average Pooling, 128 nöronlu yoğun katman(Dense) ve sınıfları belirlemek için Softmax katmanı eklendi.

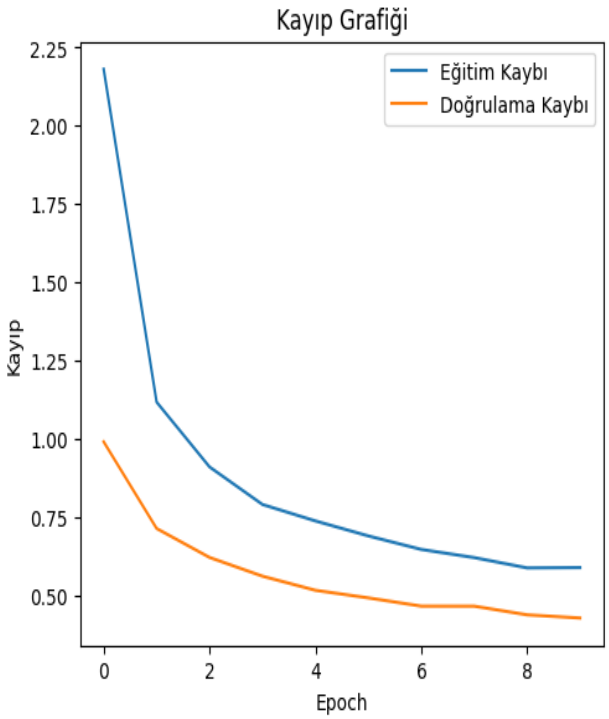
7. Hafta

Aşırı öğrenmeyi (overfitting) engellemek için %30 oranında **Dropout** katmanları eklendi.EarlyStopping (Erken Durdurma) ve ModelCheckpoint (En İyi Modeli Kaydetme) geri çağırma fonksiyonları yapılandırıldı.Model, Adam optimizasyon algoritması kullanılarak 10 epoch boyunca eğitildi.

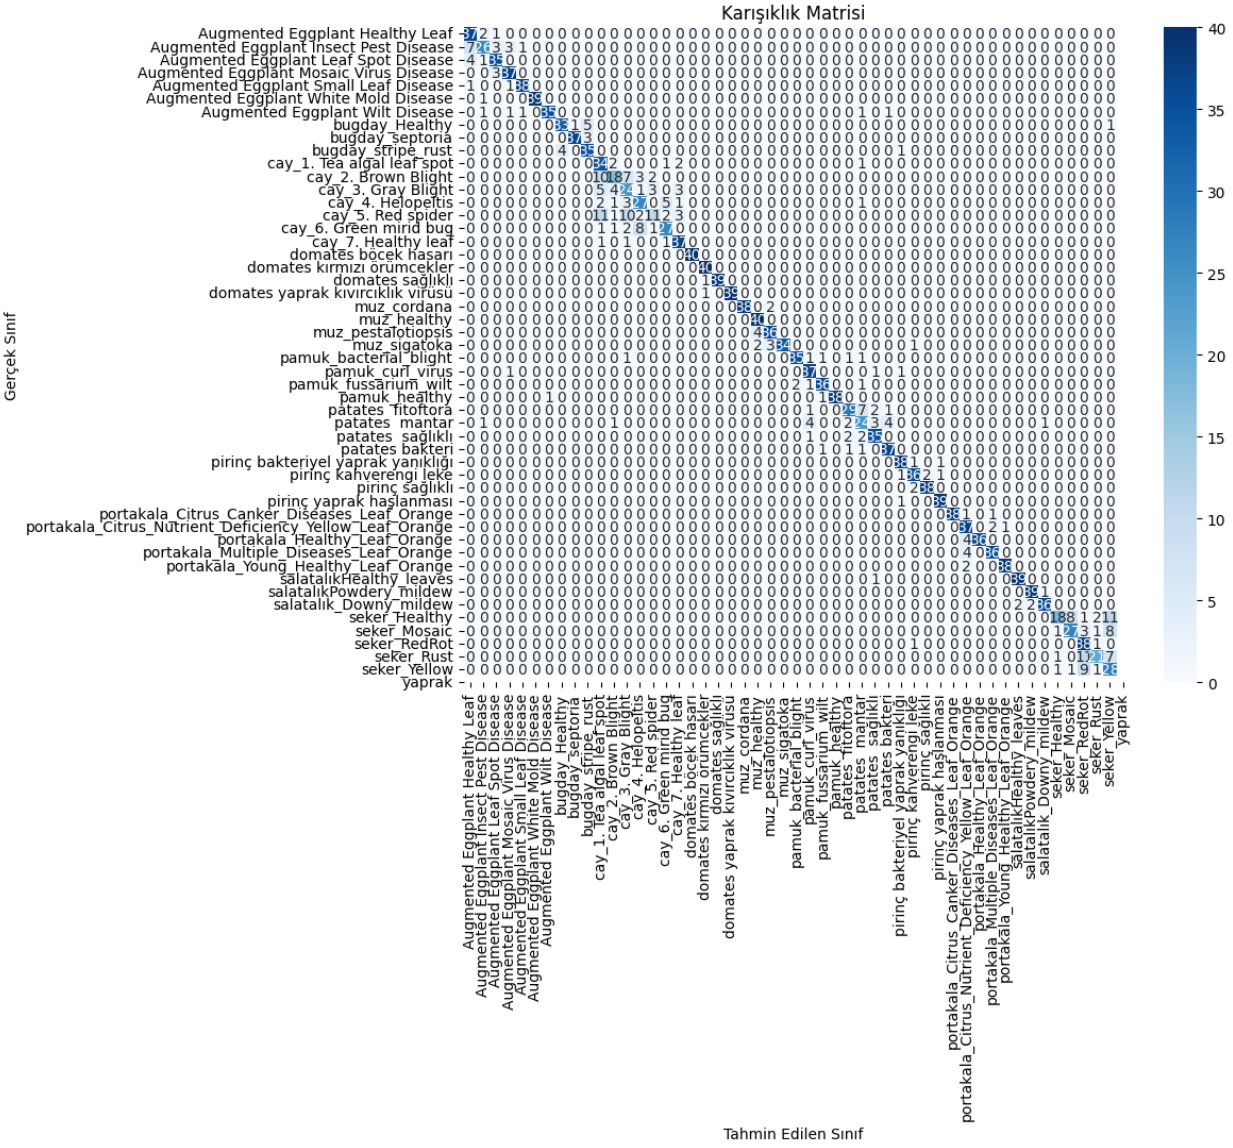
8. Hafta

Eğitim sonrası elde edilen %84 doğruluk oranı analiz edildi. Confusion Matrix (Karışıklık Matrisi) ve Classification Report (Sınıflandırma Raporu) oluşturularak hangi bitki türlerinde başarı oranının düşük olduğu tespit edildi.Yanlış tahmin edilen görüntüler incelenerek modelin hata yapma nedenleri değerlendiril


Doğruluk Grafiği
Doğruluk
Epoch
Eğitim Doğruluğu
Doğrulama Doğruluğu


Kayıp Grafiği
Kayıp
Epoch
Eğitim Kaybı
Doğrulama Kaybı

di.



9. Hafta

Eğitilen .keras formatındaki model, web arayüzünde hızlı ve optimize tahminler üretebilmesi amacıyla TensorFlow Lite (.tflite) formatına dönüştürülmüştür. Dönüşüm sonrası model boyutları kontrol edilmiş ve doğruluk testleri yapılmıştır. Vize raporu için teknik çıktılar, Accuracy/Loss grafikleri ve dokümantasyon çalışmaları tamamlanmıştır.

10. Hafta

Web uygulama geliştirme sürecine başlanmıştır. Python tabanlı Streamlit geliştirme ortamı hazırlanmış, gerekli kütüphane bağımlılıkları tanımlanmış ve proje dosya hiyerarşisi oluşturulmuştur. Platformun kullanıcı arayüzü kurumsal ve sade bir tasarımla kodlanmaya başlanmıştır.

11. Hafta

Eğitilmiş derin öğrenme modeli ve sınıf isimlerini içeren labels.txt dosyası web uygulamasına entegre edilmiştir. Tarayıcı üzerinden yüklenecek veya kamera ile çekilecek yaprak

görüntülerinin modele gönderilmeden önce 224x224 boyutuna getirilmesi, piksel değerlerinin normalize edilmesi ve veri tipinin float32 formatına dönüştürülmesi için görüntü ön işleme fonksiyonları yazılmıştır.

12. Hafta

Modelden elde edilen olasılık çıktılarının işlenmesi ve en yüksek değere sahip sınıfın saptanması amacıyla np.argmax tabanlı karar mekanizması kurulmuştur. Web arayüzünde tahmin sonuçlarının net bir şekilde gösterilebilmesi için özel CSS kodlarıyla "Analiz Bulguları" paneli tasarlanmıştır.

13. Hafta

Teşhis edilen bitki hastalıklarına göre kullanıcıya sunulacak uzman müdahale stratejileri modüler hale getirilmiştir. Projenin kod okunabilirliğini ve sürdürülebilirliğini artırmak amacıyla, 51 farklı sınıfı ve bu sınıflara ait Türkçe çözüm önerilerini içeren dev sözlük yapısı tavsiyeler.py adında ayrı bir modüle taşınarak ana koda entegre edilmiştir..

14. Hafta

Web platformunun arayüz tasarımı profesyonel standartlara getirilmiştir. Emojiler ve gereksiz görsel karmaşalar sistemden temizlenmiştir. Yazı boyutları büyütülerek okunabilirlik artırılmış, butonlar modern bir gradyan geçiş efektiyle yeniden tasarlanmıştır. Dosya yükleme ve canlı kamera bileşenleri, hangisi seçilirse sadece o modül aktif olacak şekilde dinamik bir yapıya kavuşturulmuştur.

15. Hafta

Sistem uçtan uca test edilmiştir. Farklı bitki yaprağı fotoğrafları tarayıcı üzerinden yüklenerek ve anlık kamera erişimiyle sisteme gösterilerek modelin tahmin hızı ve doğruluk performansı ölçülmüştür. Kod yapısındaki gereksiz bileşenler temizlenmiş, web platformu kararlı hale getirilmiş ve tüm ekran görüntüleri eklenerek bitirme projesi nihai raporu tamamlanmıştır.

BU ÖRNEK FORMDUR, PROJE BİLGİLERİNİ KENDİ PROJENİZE GÖRE DOLDURUNUZ.

BITKI HASTALIGI TESPITI



ANALIZI BASLAT

ANALIZ BULGULARI

Saptanan Patoloji / Durum: cay 6. Green mirid bug

Tehsis Dogruluk Orani: %83.73

UZMAN MÜDAHALE STRATEJISI

Yeşil tahtakurusu zararlısı. Kültürel önlemleri alın ve gerekiyorsa hedef odaklı insektisit kullanın.

Kaynaklar

[1] A. G. Howard ve diğerleri, “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018.

[2] TensorFlow Lite Documentation. Available: TensorFlow Lite Documentation

[3] Keras Documentation. Available: Keras Documentation

[4] TensorFlow Documentation. Available: TensorFlow Documentation

[5] Android Developers Documentation. Available: Android Developers Documentation

[6] PlantVillage Dataset. Available: PlantVillage Dataset GitHub Repository

[7] Nirmal Sankalana, “Plant Disease Test Dataset”. Available: Plant Disease Test Dataset

[8] Rashik Rahman Pritom, “Plant Disease Recognition Dataset”. Available: Plant Disease Recognition Dataset

[9] Vipoooool, “New Plant Diseases Dataset”. Available: New Plant Diseases Dataset

[10] Obeshor, “Plant Diseases Detector (Android + TensorFlow Lite)”. Available: Plant Diseases Detector GitHub Repository

[11] DevilStudio27, “Plant Disease Detection and Solution”. Available: Plant Disease Detection and Solution GitHub Repository

[12] Sami Fd, “PlantDoctor – AI Plant Disease Detection”. Available: PlantDoctor – AI Plant Disease Detection

[13] Kumar Yash, “Tomato Plant Disease Detection Model”. Available: Tomato Plant Disease Detection Model GitHub Repository

[14] Google Colab Documentation. Available: Google Colab Documentation

[15] TensorFlow Lite Support Library Documentation. Available: TensorFlow Lite Support Library Documentation